

Caracterización de zonas de riesgo de incendios forestales en la Patagonia Argentina mediante minería de datos

Agustín Formenti¹, Andrés Morenico¹, Lorenzo Mendes¹, Juan Cruz Chocobares¹

¹Minería de Datos y Big Data, Licenciatura en Ciencia de Datos, Facultad de Química e Ingeniería,

Pontificia Universidad Católica Argentina (UCA), Rosario, Argentina

aguformenti01@gmail.com andresmorenico@gmail.com mendesslorenzo@gmail.com juancruzchocobares@gmail.com

Código y datos: <https://github.com/aformen9/PatagonIA>

Resumen—Los incendios forestales en la Patagonia argentina representan una amenaza creciente para los ecosistemas nativos, con más del 95 % de los focos de ignición de origen antrópico. El presente trabajo aplica un pipeline de minería de datos no supervisada para descubrir perfiles de riesgo e identificar combinaciones de factores ambientales que co-ocurren con alta actividad histórica de fuego. Se construyó un *dataset* de 1.980 hexágonos H3 (resolución 5, $\approx 253 \text{ km}^2/\text{celda}$) y 22 variables, integrando detecciones satelitales FIRMS/VIIRS, elevación SRTM, normales climáticas NASA POWER, cobertura vegetal ESA WorldCover e infraestructura del IGN Argentina. El pipeline se implementó íntegramente en KNIME Analytics Platform e incluyó normalización Z-Score, *clustering* K-Means ($k=3$) y reglas de asociación Apriori (soporte $\geq 0,10$; confianza $\geq 0,60$). Se identificaron tres perfiles ambientales: zona húmeda andina (bajo riesgo), estepa transicional y estepa seca de alta pirofilia. El análisis de reglas revela que las zonas de alta actividad de fuego co-ocurren con condiciones cálidas, secas y de baja elevación ($\text{lift} \approx 2,05$), perfil consistente con la literatura y el *dataset* construido constituye insumo para modelado predictivo supervisado.

Index Terms—Minería de Datos, Proceso KDD, KNIME, K-Means, Apriori, incendios forestales

I. INTRODUCCIÓN

Los incendios forestales constituyen uno de los principales vectores de perturbación de los ecosistemas patagónicos y una amenaza creciente para las comunidades locales. La región presenta condiciones propicias: vastas extensiones de vegetación arbustiva seca, vientos intensos y un marcado gradiente climático este-oeste. Comprender qué combinaciones de factores —climáticos, topográficos, de vegetación y de proximidad humana— caracterizan las zonas de mayor actividad histórica de fuego es científicamente relevante y tiene implicaciones directas para la gestión del riesgo ambiental.

La minería de datos ofrece herramientas apropiadas para abordar esta pregunta de forma inductiva, extrayendo patrones estructurales de grandes volúmenes de datos satelitales y cartográficos de acceso libre sin hipótesis *a priori*. El presente trabajo construye un *dataset* geoespacial integrado

y un pipeline analítico completo en KNIME Analytics Platform para la caracterización no supervisada de los regímenes de incendio en la Patagonia argentina.

El presente trabajo se organiza de la siguiente forma: en la sección 2 se describe el dominio, se justifica el conjunto de datos y se plantea la pregunta analítica y los objetivos; en la sección 3 se revisa el estado del arte; en la sección 4 se presenta el marco teórico; en la sección 5 se detalla la metodología; en la sección 6 se presentan los resultados; en la sección 7 se realiza la discusión; y en la sección 8 se exponen las conclusiones.

II. CONTEXTO Y DEFINICIÓN DEL PROBLEMA

II-A. Dominio y justificación del conjunto de datos

El dominio elegido es la detección y análisis de incendios forestales en la Patagonia argentina (provincias de Neuquén, Río Negro, Chubut, Santa Cruz y Tierra del Fuego). La problemática es de alta relevancia ambiental: la región alberga ecosistemas únicos —estepa arbustiva, bosque andino-patagónico, pastizales de altura— que enfrentan una presión creciente por el fuego, agravada por el cambio climático y el avance de la frontera antrópica.

El conjunto de datos fue construido *ad hoc* a partir de cinco fuentes de acceso libre y citables: (1) detecciones FIRMS VIIRS Collection 2 descargadas de firms.modaps.eosdis.nasa.gov; (2) elevación SRTM 30 m vía API OpenTopoData; (3) normales climáticas 1981–2020 de la NASA POWER Climatology API [7]; (4) cobertura vegetal ESA WorldCover 2021 [8]; y (5) infraestructura vial y poblacional del IGN Argentina (servicio WFS público). El *dataset* contiene 1.980 registros y 22 variables (11 numéricas de régimen de fuego, 5 de terreno y clima, 1 categórica de vegetación, 2 de presión humana y 3 identificadores geográficos), sin valores faltantes. De estas, 19 son analíticas y 3 (*hex*, *lat*, *lon*) son identificadores excluidos en el análisis mediante *Column Filter*. Ninguna de estas fuentes fue trabajada en las clases prácticas de la materia.

II-B. Pregunta analítica y alcance

La pregunta analítica que guía el trabajo es: *¿Qué perfiles ambientales caracterizan las zonas con mayor actividad histórica de incendios en la Patagonia argentina, y qué combinaciones de factores climáticos, de vegetación y de presión humana se asocian con alta ocurrencia de focos?*

Esta pregunta amerita un abordaje mediante minería de datos porque involucra múltiples variables heterogéneas (numéricas continuas y categóricas), un volumen de datos no trivial (1.980 observaciones geoespaciales derivadas de más de 400.000 detecciones satelitales originales) y la búsqueda de patrones estructurales sin etiquetas supervisadas disponibles.

El alcance comprende el análisis no supervisado del período 2012–2023, limitado a la región $[-56, -38]$ lat $\times$ $[-76, -62]$ lon. Quedan fuera del alcance el modelado predictivo supervisado, el análisis temporal intra-anual y la validación en campo.

II-C. Objetivos y resultado esperado

Objetivo general: Descubrir y caracterizar los perfiles de riesgo de incendio forestal en la Patagonia argentina mediante un pipeline de minería de datos construido en KNIME, a partir de datos satelitales y cartográficos de acceso libre.

Objetivos específicos:

- OE1 — Construir un *dataset* reproducible integrando cinco fuentes satelitales y cartográficas públicas, con al menos 1.000 registros y 8 variables.
- OE2 — Diseñar y ejecutar el pipeline de ingesta, preprocesamiento y análisis exploratorio en KNIME Analytics Platform.
- OE3 — Realizar el análisis exploratorio de datos (EDA): estadísticos descriptivos, distribuciones y correlaciones entre variables ambientales y de régimen de fuego.
- OE4 — Aplicar K-Means y Apriori para descubrir e interpretar perfiles de riesgo y reglas de asociación entre factores ambientales.

Resultado esperado: Un pipeline completo, documentado y funcional en KNIME (archivo `.knwf`), junto con los patrones descubiertos (agrupamientos ambientales y reglas de asociación) que respondan a la pregunta analítica. El criterio de éxito es que los *clusters* sean interpretables geográficamente y que las reglas obtenidas sean coherentes con el conocimiento previo del dominio.

III. ESTADO DEL ARTE

Los incendios forestales en la Patagonia han sido estudiados desde perspectivas ecológicas y geográficas. Kitzberger *et al.* [1] analizaron la relación entre composición vegetal, historia de fuego y régimen de incendios en la Patagonia, identificando la distancia al asentamiento humano como el predictor estático más robusto de la ocurrencia de incendios, con el 95 % de los focos de origen antrópico. Este resultado fundamenta la inclusión de variables de presión humana en el presente *dataset*.

En materia de detección satelital, Schroeder *et al.* [2] introdujeron el producto VIIRS 375m para la detección de incendios activos, demostrando su superioridad frente a MODIS (~ 1 km) en la localización precisa de focos de pequeña extensión. Este producto es hoy el estándar operacional de monitoreo de incendios, adoptado en el presente trabajo.

Desde el punto de vista de la minería de datos, Han *et al.* [3] presentan los fundamentos del proceso KDD y los algoritmos de *clustering* y reglas de asociación aplicables a grandes volúmenes de datos geoespaciales. En este contexto, el agrupamiento K-Means ha sido ampliamente utilizado para segmentar zonas de riesgo ambiental, mientras que Apriori se aplica en la identificación de combinaciones de condiciones precursoras de eventos naturales.

El presente trabajo se diferencia del estado del arte en que construye un *dataset* integrado *multi-fuente* específico para la Patagonia argentina y aplica el proceso KDD completo en KNIME, aportando un análisis conjunto de *clustering* y reglas de asociación en una plataforma reproducible y documentada.

IV. MARCO TEÓRICO

IV-A. Proceso KDD

El proceso KDD (*Knowledge Discovery in Databases*) fue definido por Fayyad *et al.* [4] como el proceso no trivial de identificar patrones válidos, novedosos, potencialmente útiles y comprensibles en datos. Comprende cinco etapas: (1) Selección del subconjunto de datos relevante; (2) Preprocesamiento (limpieza, tratamiento de valores faltantes, codificación); (3) Transformación (normalización, discretización); (4) Minería de datos (aplicación de algoritmos); y (5) Evaluación e interpretación de los patrones descubiertos. El presente trabajo sigue este proceso íntegramente en KNIME Analytics Platform.

IV-B. Grilla Hexagonal H3

H3 es un sistema de indexación geoespacial jerárquica basado en hexágonos desarrollado por Uber [9]. En la resolución 5 ($\approx 253 \text{ km}^2/\text{celda}$), los seis vecinos de cada hexágono se encuentran exactamente a la misma distancia del centroide, propiedad que elimina la anisotropía de las grillas cuadradas (cuyos vecinos diagonales están $\sqrt{2} \approx 1,41$ veces más lejos que los cardinales). Esta propiedad es relevante para la asignación no ambigua de fuentes de datos a unidades de análisis geoespacial.

IV-C. Agrupamiento K-Means

K-Means [5] es un algoritmo de agrupamiento no supervisado que particiona n observaciones en k conglomerados minimizando la suma de cuadrados intracluster (WCSS). El algoritmo itera asignando cada observación al centroide más cercano y recalculando los centroides hasta la convergencia. Requiere que las variables estén previamente normalizadas, ya que utiliza distancia euclidiana: sin normalización, las variables de mayor escala dominarían el cálculo de distancias.

IV-D. Reglas de Asociación — Apriori

Las reglas de asociación tienen la forma $A \Rightarrow B$ e indican que si se observa el conjunto de ítems A , es probable encontrar también B [6]. Se evalúan por tres métricas: (1) **Soporte**: fracción de transacciones que contienen $A \cup B$; (2) **Confianza**: probabilidad condicional $P(B|A)$; y (3) **Lift**: razón entre la confianza de la regla y el soporte del consecuente — un $lift > 1$ indica que A aumenta la probabilidad de B respecto al azar. El algoritmo Apriori explora eficientemente el espacio de ítems frecuentes usando la propiedad antimonotónica: si un conjunto es infrecuente, todos sus superconjuntos también lo son. Requiere que las variables numéricas sean previamente discretizadas en categorías.

V. METODOLOGÍA

V-A. Conjunto de datos

El *dataset* fue construido en Python mediante un pipeline de cinco pasos encadenados con archivos intermedios en formato Parquet para garantizar reproducibilidad y control de calidad por etapa. La unidad de análisis es el hexágono H3 de resolución 5; se incluyeron los 1.980 hexágonos con al menos un foco registrado entre 2012 y 2023.

Las 22 variables se organizan en cinco grupos: (i) identificadores geográficos (*hex*, *lat*, *lon*); (ii) régimen de fuego — 11 variables de conteo, brillo radiativo, FRP, estacionalidad y recurrencia derivadas de FIRMS VIIRS; (iii) terreno y clima — elevación SRTM, temperatura media, precipitación anual, viento medio y humedad relativa de NASA POWER Climatology; (iv) cobertura vegetal — clase dominante de ESA WorldCover 2021; y (v) presión humana — distancias a asentamiento y a ruta nacional del IGN Argentina. El *dataset* no presenta valores faltantes.

V-B. Preprocesamiento y pipeline en KNIME

La Fig. 1 presenta el *workflow* completo en KNIME con anotaciones descriptivas en cada nodo.

CSV Reader carga el *dataset*. *Column Filter* excluye los identificadores geográficos (*hex*, *lat*, *lon*) que no aportan información analítica. *Statistics* y *Scatter Matrix* constituyen la etapa de EDA.

Para la rama de K-Means, *Normalizer* aplica Z-Score a las 18 variables numéricas: sin normalización, variables de alta escala ($n_focos \in [1; 5.406]$) dominarían sobre variables acotadas ($pct_noche \in [0; 1]$). Para la rama de Apriori, *Denormalizer* revierte el Z-Score; *Numeric Binner* discretiza 7 variables continuas con etiquetas descriptivas (Tabla I); y *Columns to Collection* convierte al formato *Collection Set* requerido por el nodo *Association Rule Learner*.

V-C. Herramientas analíticas aplicadas

K-Means se configuró con $k=3$, distancia euclidiana, máximo 99 iteraciones y semilla fija (0) para reproducibilidad. Se eligió $k=3$ porque la Patagonia presenta al menos tres perfiles ambientales cualitativamente distintos: zona andina

húmeda, estepa transicional y estepa árida pirofílica. *Color Manager* asigna colores por *cluster* para las visualizaciones (*Scatter Plot* y *Box Plot*).

Apriori se configuró con soporte mínimo de 0,10 (un patrón debe aparecer en al menos 198 de las 1.980 zonas para ser considerado estructural y no anecdótico) y confianza mínima de 0,60. El nodo *Row Filter* retiene únicamente las reglas con $lift \geq 1,2$, garantizando que el antecedente aporte al menos un 20 % de probabilidad adicional sobre el consecuente.

VI. RESULTADOS

VI-A. Análisis exploratorio de datos (EDA)

La Fig. 2 muestra el output completo del nodo *Statistics* para las 19 variables analíticas.

Se observa un fuerte desbalance en *n_focos*: media 88,1 vs. máximo 5.406, asimetría positiva de 10,8 y curtosis de 184,1, indicativo de que pocas zonas concentran actividad extrema de fuego. *precip_anual* presenta alta variabilidad ($CV \approx 52\%$), coherente con el gradiente este-oeste patagónico. Las variables *dist_asentamiento_km* y *dist_ruta_km* muestran distribuciones sesgadas a la derecha, con zonas de hasta 180 y 155 km de aislamiento.

VI-B. Visualización de datos

La Fig. 3 presenta la *Scatter Matrix* de las variables de fuego y brillo radiativo.

Se observa correlación positiva entre *n_focos* y ambas variables de brillo, indicando que las zonas de mayor actividad histórica también registran focos de mayor intensidad radiativa.

VI-C. Resultados de las técnicas de minería

K-Means. Las Figs. 4 y 5 presentan los resultados del agrupamiento.

Apriori. La Fig. 6 muestra el output filtrado. Se generaron 184 reglas que superan $lift \geq 1,2$. La Tabla II resume las reglas de mayor relevancia, distinguiendo las que caracterizan el perfil ambiental de las zonas de alta actividad de fuego de las que describen co-ocurrencias ambientales generales.

VI-D. Descubrimiento e interpretación de patrones

Los tres *clusters* K-Means corresponden a perfiles ambientales diferenciados:

- **cluster_1 (rojo) — Estepa seca pirofílica:** concentrado en baja precipitación ($Z \approx -1$) con los valores más elevados de *n_focos* (valores atípicos hasta $Z = 22$). Es la zona de mayor riesgo histórico, característica de las mesetas áridas de Neuquén y Río Negro.
- **cluster_2 (naranja) — Estepa transicional:** precipitación baja a media y actividad de fuego moderada (valores atípicos hasta $Z = 10$). Representa una zona de riesgo intermedio con mayor heterogeneidad ambiental.
- **cluster_0 (verde) — Zona húmeda/andina:** amplio rango de precipitación (Z hasta $+4$) con *n_focos*




Figura 1: Workflow KNIME con anotaciones. Rama superior: EDA y *clustering* K-Means. Rama inferior: discretización y reglas de asociación Apriori. Todos los nodos ejecutados sin errores.

Cuadro I: Discretización de variables para Apriori (nodo *Numeric Binner*)

Variable	Categorías	Umbrales	Justificación
n_focos	foco_bajo / foco_medio / foco_alto	<20 / 20–150 / >150 focos	Percentiles aproximados de la distribución
temp_media	fría / templada / cálida	<5 / 5–13 / ≥13 °C	Umbrales ecológicos patagónicos
precip_anual	seca / semi / húmeda	<300 / 300–600 / ≥600 mm	Clasificación árida / semiárida / húmeda
viento_medio	moderado / fuerte	<5 / ≥5 m/s	Umbral operacional SNMF
humedad relativa	seca / húmeda	<60 / ≥60 %	Umbral de déficit hídrico atmosférico
dist. asentam.	cercano / lejano	<50 / ≥50 km	Rango de influencia antrópica directa
elevacion	baja / media / alta	<200 / 200–800 / ≥800 m	Pisos altitudinales patagónicos

Cuadro II: Reglas de asociación seleccionadas (mayor *lift*). La etiqueta *baja* corresponde a elevación (<200 m); *seca* a precipitación anual (<300 mm).

Regla	Sop.	Conf.	Lift
<i>Co-ocurrencia con alta actividad de fuego</i>			
{foco_alto, baja} ⇒ calida	0,100	0,975	2,052
{calida, foco_alto} ⇒ baja	0,100	0,731	2,052
{foco_alto, seca} ⇒ calida	0,127	0,965	2,031
<i>Co-ocurrencia ambiental general</i>			
{calida, lejano} ⇒ matorral	0,104	0,827	1,995
{calida, seca} ⇒ matorral	0,317	0,814	1,964

consistentemente bajos. Comprende el corredor andino y las zonas de mayor humedad relativa.


El análisis de reglas de asociación revela dos grupos de patrones. El primero conecta directamente la actividad de fuego con condiciones ambientales: las reglas {foco_alto, baja} ⇒ calida (*lift* = 2,052; confianza = 0,975) y {foco_alto, seca} ⇒ calida (*lift* = 2,031; confianza = 0,965) indican que las zonas de alta actividad histórica de fuego co-ocurren con condiciones cálidas, secas y de baja elevación. El segundo grupo describe co-ocurrencias ambientales

generales, como {calida, lejano} ⇒ matorral (*lift* = 1,995), que asocia zonas cálidas y alejadas de asentamientos con cobertura de matorral, el combustible seco predominante en la región. Es importante señalar que Apriori mide co-ocurrencia y no causalidad ni dirección predictiva; estas reglas caracterizan el perfil ambiental de las zonas de alta pirofilia, sin constituir un modelo de predicción.


VII. DISCUSIÓN

Los resultados del *clustering* reproducen inductivamente la tripartición ambiental clásica de la Patagonia: corredor andino húmedo, estepa arbustiva transicional y estepa árida pirofílica. Esta correspondencia con el conocimiento geográfico previo sin utilizar etiquetas supervisadas otorga validez externa al agrupamiento, y es consistente con los perfiles de riesgo documentados por Kitzeberger *et al.* [1].


Las reglas de asociación descubiertas son coherentes con los mecanismos físicos conocidos: las zonas de alta actividad de fuego co-ocurren con condiciones cálidas, secas y de baja elevación, y la cobertura de matorral —combustible seco predominante en incendios de alta intensidad— se asocia con zonas cálidas y alejadas de asentamientos [1]. Esta convergencia con el estado del arte, y con los perfiles



(a) Variables de régimen de fuego: n_focos, brillo_medio, brillo_max, frp_medio, frp_max, brillo_t31_medio.



(b) Porcentajes y recurrencia: pct_noche, pct_verano, pct_conf_alta, n_anios_activo, mes_pico, elevacion.



(c) Variables climáticas y presión humana: temp_medio, precip_anual, viento_medio, humedad_relativa, dist_asentamiento_km, dist_ruta_km.

Figura 2: Output del nodo *Statistics* (KNIME). 19 variables, 0 valores faltantes. Los histogramas (columna derecha) ilustran la distribución de cada variable.




Figura 3: *Scatter Matrix*: n_focos , $brillo_medio$ y $brillo_max$. La correlación $brillo_medio \leftrightarrow brillo_max$ es casi perfecta ($r \approx 0,98$) por tratarse del mismo canal VIIRS con diferente agregación temporal.




Figura 4: *Scatter Plot* coloreado por *cluster*: precipitación anual vs. n_focos (escala Z-Score). Verde: *cluster_0*; naranja: *cluster_2*; rojo: *cluster_1*.




Figura 5: *Box Plot* de n_focos (Z-Score) por *cluster*. Los valores atípicos de *cluster_1* (rojo) alcanzan $Z = 22$, correspondiendo a zonas de actividad extrema.

#	RowID	Support # Number (float)	Confidence # Number (float)	Lift # Number (float)	Consequent # Item	Implies # Item	Items
98	rule15	0.172	0.832	2.336	baja	←	[baja,semit]
132	rule20	0.216	0.747	2.098	baja	←	[calida,semit]
50	rule72	0.127	0.733	2.657	baja	←	[seca,semit]
2	rule1	0.1	0.975	2.652	calida	←	[foco,alta,baja]
1	rule0	0.1	0.731	2.652	baja	←	[calida,baja,alta]
15	rule24	0.112	0.729	2.648	baja	←	[maternal,semit]
48	rule69	0.127	0.965	2.631	calida	←	[foco,alta,seca]
120	rule19	0.194	0.953	2.605	calida	←	[baja,maternal]
8	rule11	0.104	0.827	1.965	maternal	←	[calida,semit]
72	rule10	0.138	0.878	1.968	templada	←	[alta,semit]

Figura 6: Output del nodo *Row Filter* (KNIME). 184 reglas de asociación filtradas por $lift \geq 1,2$.

obtenidos independientemente por el *clustering* K-Means, refuerza la validez de los patrones identificados mediante triangulación metodológica.

Un resultado esperado fue la correlación casi perfecta entre $brillo_medio$ y $brillo_max$ (ambas miden temperatura radiativa VIIRS en el mismo canal), lo que sugiere que una de las dos podría eliminarse en análisis futuros. Un resultado destacado fue la extrema concentración de la actividad de fuego: el *cluster* pirofílico concentra valores atípicos de hasta $Z = 22$, lo que refleja que pocas zonas de la estepa árida concentran la mayor parte de la actividad histórica de fuego.

La elección de $k = 3$ se justificó por criterio de dominio experto; el coeficiente de silueta permitiría validar cuantitativamente este valor en investigaciones futuras. Asimismo, Apriori trata las observaciones como independientes, sin considerar la autocorrelación espacial entre hexágonos vecinos, lo que constituye una limitación inherente del método que podría abordarse mediante DBSCAN geoespacial o indicadores locales de asociación espacial (LISA).

VIII. CONCLUSIONES

Este trabajo demostró que la combinación de K-Means y Apriori implementada íntegramente en KNIME permite caracterizar de forma no supervisada los regímenes de incendio en la Patagonia argentina. Los hallazgos principales son:

1. K-Means ($k=3$) identifica tres perfiles diferenciados que se corresponden con las grandes unidades ecológicas de la Patagonia: zona húmeda/andina (bajo riesgo), estepa transicional y estepa seca pirofílica (alto riesgo).
2. Las reglas de asociación de mayor *lift* ($\{\text{foco_alto, baja}\} \Rightarrow \text{calida}$ y $\{\text{foco_alto, seca}\} \Rightarrow \text{calida}$, $\text{lift} \approx 2,05$) revelan que la alta actividad histórica de fuego co-ocurre con un perfil cálido, seco y de baja elevación, consistente con la estepa árida pirofílica identificada por el *clustering*.
3. El *dataset* construido (1.980 hexágonos H3, 22 variables, 0 valores faltantes) es reproducible desde fuentes públicas y constituye la base para el modelado predictivo supervisado de riesgo de incendio en trabajos futuros de IA y *Machine Learning*.

Las implicaciones prácticas incluyen la posibilidad de priorizar zonas de monitoreo preventivo en función del perfil de *cluster* y las reglas descubiertas, como insumo directo para el Sistema Nacional de Manejo del Fuego (SNMF).

REFERENCIAS

- [1] T. Kitzberger *et al.*, "Clear links between plant community composition, fire history and fire regime in Patagonia," *Forest Ecology and Management*, vol. 374, pp. 1–11, 2016.
- [2] W. Schroeder, P. Oliva, L. Giglio e I. A. Csizsar, "The New VIIRS 375 m active fire detection data product: Algorithm description and initial assessment," *Remote Sensing of Environment*, vol. 143, pp. 85–96, 2014.
- [3] J. Han, M. Kamber y J. Pei, *Data Mining: Concepts and Techniques*, 3.a ed. Waltham, MA: Morgan Kaufmann, 2011.
- [4] U. M. Fayyad, G. Piatetsky-Shapiro y P. Smyth, "From data mining to knowledge discovery in databases," *AI Magazine*, vol. 17, no. 3, pp. 37–54, 1996.
- [5] J. MacQueen, "Some methods for classification and analysis of multivariate observations," en *Proc. 5th Berkeley Symp. Math. Stat. Prob.*, Berkeley, CA, 1967, pp. 281–297.
- [6] R. Agrawal y R. Srikant, "Fast algorithms for mining association rules," en *Proc. 20th Int. Conf. Very Large Data Bases (VLDB)*, Santiago, Chile, 1994, pp. 487–499.
- [7] P. W. Stackhouse *et al.*, "NASA POWER Release 9," *NASA Technical Report*, power.larc.nasa.gov, 2019.
- [8] D. Zanaga *et al.*, "ESA WorldCover 10m 2021 v200," Zenodo, doi:10.5281/zenodo.7254221, 2022.
- [9] Uber Engineering, "H3: Uber's Hexagonal Hierarchical Spatial Index," 2018. [En línea]. Disponible: <https://github.com/uber/h3>